

数理统计

样本与统计量

1. 总体

在数理统计中所研究对象的某项数量指标 X 取值的全体称为总体。
 X 是一个随机变量, X 的分布函数和数字特征分别称为总体的分布函数和数字特征。

2. 个体

总体中的每个元素称为个体, 每个个体是一个实数。

3. 总体容量


总体中个体的数量称为总体的容量. 容量为有限的总体称为有限总体, 容量为无限的总体称为无限总体。

4. 简单随机样本

与总体 X 具有相同的分布, 并且每个个体 $X_1, X_2, \dots, X_n$ 之间是相互独立的, 则称 $X_1, X_2, \dots, X_n$ 为来自总体 X 的简单随机样本, 简称样本, n 称为样本容量。它们的观测值 $x_1, x_2, \dots, x_n$ 称为样本观测值, 简称为样本值。

常见统计量 (1) 统计量

设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, $g(t_1, t_2, \dots, t_n)$ 是一个不含未知数的 n 元函数, 则称随机变量 $x_1, x_2, \dots, x_n$ 的函数 $T = g(X_1, X_2, \dots, X_n)$ 为一个统计量。设 $x_1, x_2, \dots, x_n$ 是相应于 $X_1, X_2, \dots, X_n$ 的样本值, 则称 $g(x_1, x_2, \dots, x_n)$ 为统计量 $T = g(X_1, X_2, \dots, X_n)$ 的观测值。



(1) 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 观测值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

$$E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}$$

我的理解: 统计量的观测值是真实值的近似值

(2) 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$ 。

样本标准差 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$, 观测值为 $s = \sqrt{\frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)}$ 。

$$E(S^2) = E \left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right] = \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i^2) - nE(\bar{x}^2) \right] = \sigma^2。$$

(3) 样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, 观测值为 $a_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, ($k=1, 2, \dots$)。

(4) 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, 观测值为 $b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$, ($k=1, 2, \dots$)。

(5) 顺序统计量 $X_{(n)} = \max(X_1, X_2, \dots, X_n)$ 和 $X_{(l)} = \min(X_1, X_2, \dots, X_n)$

设总体 X 的分布函数为 $F(x)$, $X_1, X_2, \dots, X_n$ 是来自总体 x 的样本, 则统计量 $X_{(n)} = \max(X_1, X_2, \dots, X_n)$ 的分布函数为

$$F_{\max}(x) = P\{X_{(n)} = \max(X_1, X_2, \dots, X_n) \leq x\} = [F(x)]^n。$$

$X_{(l)} = \min(X_1, X_2, \dots, X_n)$ 的分布函数为

$$F_{\min}(x) = P\{X_{(l)} = \min(X_1, X_2, \dots, X_n) \leq x\} = 1 - [1 - F(x)]^n。$$

原点矩

x 为 X 的样本, 若 $X \sim E(\lambda)$, 则 $F_{\min}(x) = 1 - [1 - F(x)]^n \sim E(n\lambda)$

样本与抽样分布

抽样分布 1. χ^2 分布

(1) 典型模式

设随机变量 $X_1, X_2, \dots, X_n$ 相互独立, 都服从标准正态分布 $N(0, 1)$, 则随机变量 χ^2


$X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布, 记作 $\chi^2 \sim \chi^2(n)$ 。

$$\chi^2(n) \text{ 分布的概率密度为 } f(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

(2) χ^2 分布的性质

① 设 $\chi_1^2 \sim \chi_1^2(n_1)$, $\chi_2^2 \sim \chi_1^2(n_2)$, 并且 χ_1^2 和 χ_2^2 相互独立, 则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$ 。

② 如果 $\chi^2 \sim \chi^2(n)$, 则有 $E(\chi^2) = n$, $D(\chi^2) = 2n$ 。




抽样分布 2. t 分布

(1) 典型模式

设随机变量 X, Y 相互独立, 且 $X \sim N(0, 1), Y \sim \chi^2(n)$, 则随机变量 $t = \frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布, 记作 $t \sim t(n)$.

$$t(n) \text{ 分布的概率密度为 } f(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < x < +\infty.$$



(2) 性质

$t(n)$ 分布的概率密度 $f(x)$ 是偶函数且有 $\lim_{n \rightarrow \infty} f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$, 即当 n 充分大时, $t(n)$ 分布近似 $N(0, 1)$ 分布.


student分布

抽样分布 3. F 分布

(1) 典型模式

设随机变量 X, Y 相互独立, 且 $X \sim \chi^2(m), Y \sim \chi^2(n)$, 则随机变量 $F = \frac{X/m}{Y/n}$ 服从自由度为 (m, n) 的 F 分布, 记作 $F \sim F(m, n)$, 其概率密度为

$$f(x) = \begin{cases} \frac{\Gamma\left(\frac{n+m}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n}\right) \left(\frac{m}{n}x\right)^{\frac{m}{2}-1} \left(1 + \frac{m}{n}x\right)^{-\frac{m+n}{2}} & x \geq 0 \\ 0 & x < 0 \end{cases}$$



(2) 性质

设 $F \sim F(m, n)$, 则 $\frac{1}{F} \sim F(n, m)$.

正态总体下的抽样分布

1. 一个正态总体

设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $X \sim N(\mu, \sigma^2)$ 的样本, 样本均值为 $\bar{X}$, 样本方差为 S^2 , 则有:

$$(1) \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

$$(2) \bar{X} \text{ 与 } S \text{ 相互独立, 且 } \frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] \sim \chi^2(n-1).$$

$$(3) T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

$$(4) \chi^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n), \quad \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

2. 两个正态总体

设 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_n$ 分别来自总体 X 和 Y 的样本, 且两个总体相互独立, 则有

$$(1) \bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right), U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1).$$

$$(2) \text{ 如果 } \sigma_1^2 = \sigma_2^2 \text{ 则 } T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2), \text{ 其中 } S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

$$(3) F = \frac{n_2 \sigma_2^2 \sum_{i=1}^{n_1} (X_i - \mu_1)^2}{n_1 \sigma_1^2 \sum_{i=1}^{n_2} (Y_i - \mu_2)^2} \sim F(n_1, n_2)$$

$$(4) F = \frac{\sigma_2^2 S_1^2}{\sigma_1^2 S_2^2} \sim F(n_1 - 1, n_2 - 1)$$

参数估计

点估计

确定某个参数的确定值

点估计的概念

设总体 X 的分布形式已知, 但含有未知参数 θ ; 或者总体的某数字特征存在但未知.

$X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, $x_1, x_2, \dots, x_n$ 是相应的样本值. 所谓的点估计就是构造

一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 用它估计未知参数 θ , 用它的观测值

$\hat{\theta}(x_1, x_2, \dots, x_n)$ 作为未知参数 θ 的近似值, 称统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为未知参数 θ 的

估计量, $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的一个估计值.

我的理解: 从数据中计算中计算统计量的估计量

矩估计

矩法的基本思想是用样本的 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 作为总体的 k 阶原点矩

$\mu_k = E(X^k)$ 的估计.

$$\mu_l = E(X^l) = \int_{-\infty}^{\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx \quad (X \text{ 连续型})$$

或

$$\mu_l = E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \theta_2, \dots, \theta_k) \quad (X \text{ 离散型})$$

$l=1, 2, \dots, k$

求解答案不唯一，可以产生多个方程

最大似然估计

1) 离散型随机变量

设总体 X 是离散型随机变量，概率分布为 $P\{X=t_i\} = p(t_i; \theta), i=1, 2, \dots$ 其中 $\theta \in \Theta$ 为待估参数.

设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本， $x_1, x_2, \dots, x_n$ 是样本值，称函数

$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$ 为样本 $x_1, x_2, \dots, x_n$ 的似然函数. 如果 $\hat{\theta} \in \Theta$ ，使得

$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$ ，这样的 $\hat{\theta}$ 与 $x_1, x_2, \dots, x_n$ 有关，记作 $\hat{\theta}(x_1, x_2, \dots, x_n)$ ，称为未知参数 θ

的最大似然估计值，相应的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的最大似然估计量.

2) 连续型随机变量


设总体 X 的概率密度函数 $f(x; \theta)$ ，其中 $\theta \in \Theta$ 为待估参数，设 $x_1, x_2, \dots, x_n$ 是来自总体 X

的样本 $x_1, x_2, \dots, x_n$ 是样本值，称函数 $L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$ 为样本

$x_1, x_2, \dots, x_n$ 的似然函数. 如果 $\hat{\theta} \in \Theta$ ，使得 $L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$ ，这样的 $\hat{\theta}$ 与 $x_1, x_2, \dots, x_n$ 有

关，记作 $\hat{\theta}(x_1, x_2, \dots, x_n)$ ，称为未知参数 θ 的最大似然估计值，相应的统计量

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的最大似然估计量.



我的理解: 一系列积事件概率最大的 θ

3) 最大似然估计法的步骤

① 写出似然函数

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_m) = \prod_{i=1}^n P(x_i; \theta_1, \theta_2, \dots, \theta_m) \quad (\text{离散型})$$

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_m) = \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_m); \quad (\text{连续型})$$

② 取对数 $\ln L$;

③ 对 $\theta_1, \theta_2, \dots, \theta_m$ 求偏导数 $\frac{\partial \ln L}{\partial \theta_i}, i = 1, 2, \dots, m$

④ 判断方程组 $\frac{\partial \ln L}{\partial \theta_i}$ 是否有解. 若有解, 则其解即为所求最大似然估计; 若无解, 则最大似

然估计常在 θ_i 的边界点上达到.


区间估计

将参数确定在某个区间中的概率(置信度)

矛盾: 置信度和精度

区间估计

(1) 四大分布的分位数(点). 其中 α 称为显著水平, $1 - \alpha$ 称为置信度(置信水平)



上 α 分布点 $P(X > U_\alpha) = \alpha$

区间估计 (2) 置信区间

设总体 X 的分布函数 $F(x; \theta)$ 含有一个未知参数 $\theta \in \Theta$ (Θ 是 θ 可能取值的范围), 对于给定值 $\alpha (0 < \alpha < 1)$ 若由来自 X 的样本 $X_1, X_2, \dots, X_n$ 确定的两个统计量 $\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)$ 和 $\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)$ ($\underline{\theta} < \bar{\theta}$), 对于任意 $\theta \in \Theta$ 满足

$$P\{\underline{\theta}(X_1, X_2, \dots, X_n) < \theta < \bar{\theta}(X_1, X_2, \dots, X_n)\} \geq 1 - \alpha,$$

则称随机区间 $(\underline{\theta}, \bar{\theta})$ 是 θ 的置信水平为 $1 - \alpha$ 的置信区间, $\underline{\theta}$ 和 $\bar{\theta}$ 分别称为置信水平为 $1 - \alpha$ 的双侧置信区间的置信下限和置信上限, $1 - \alpha$ 称为置信水平.

区间估计 (2) 置信区间

(1) $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$, $U = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$.

(2) $\bar{X}$ 与 S 相互独立, 且 $\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] \sim \chi^2(n-1)$.

(3) $T = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$

(4) $\chi^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$, $\frac{S_1^2 / S_2^2}{\sigma_1^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$

区间估计 (2) 置信区间

待估参数	其他参数	枢轴量 W 的分布	置信区间	单侧置信限
μ	σ^2 已知	$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$	$\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$	$\bar{\mu} = \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha}$ $\underline{\mu} = \bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha}$

待估参数	其他参数	枢轴量 W 的分布	置信区间	单侧置信限
μ	σ^2 未知	$t = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$	$\left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$	$\bar{\mu} = \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha}(n-1)$ $\underline{\mu} = \bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1)$
σ^2	μ 未知	$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right)$	$\bar{\sigma}^2 = \frac{(n-1)S^2}{\chi^2_{1-\alpha}(n-1)}$ $\underline{\sigma}^2 = \frac{(n-1)S^2}{\chi^2_{\alpha}(n-1)}$

区间估计 (2) 置信区间

② 两正态总体的均值差与方差比的置信区间

设 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$. 从总体 X 中抽取样本 $X_1, X_2, \dots, X_{n_1}$, 样本均值为 $\bar{X}$, 样本方差为 S_1^2 ; 从总体 Y 中抽取样本 $Y_1, Y_2, \dots, Y_{n_2}$, 样本均值为 $\bar{Y}$, 样本方差为 S_2^2 , 且两个样本相互独立.

(1) 两个正态总体均值差 $\mu_1 - \mu_2$ 的置信区间.

(a) σ_1^2, σ_2^2 均已知, $\mu_1 - \mu_2$ 的置信度为 $1 - \alpha$ 的置信区间为

$$(\bar{X} - \bar{Y} - u_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}, \bar{X} - \bar{Y} + u_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}).$$

(b) $\sigma_1^2 = \sigma_2^2 = \sigma^2$, σ^2 未知, $\mu_1 - \mu_2$ 的置信度为 $1 - \alpha$ 的置信区间为

$$(\bar{X} - \bar{Y} - t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{1/n_1 + 1/n_2}, \bar{X} - \bar{Y} + t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{1/n_1 + 1/n_2}),$$

其中


$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}, S_w = \sqrt{S_w^2}.$$

值得注意的是: 当方差 σ_1^2, σ_2^2 未知, 求期望差 $\mu_1 - \mu_2$ 的置信区间时, 前提条件是 $\sigma_1^2 = \sigma_2^2$. 否则不能使用公式

(2) 两个正态总体方差比 σ_1^2/σ_2^2 的置信区间为 μ_1, μ_2 为未知, σ_1^2/σ_2^2 的置信度为 $1 - \alpha$ 的置信区间为

$$\left(\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right).$$

假设检验



α — 显著性水平

α 错误	β 错误
拒绝假设 H_0 H_0 为真	接受假设 H_0 H_0 为假
被判有罪 实际无罪	被判无罪 实际有罪

一般选择 β 错误

(1) U — 检验 (σ^2 已知)

1) 设 $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$;

2) 选择统计量 $Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}} \sim N(0, 1)$;

3) 接受域 $(-z_{\frac{\alpha}{2}}, z_{\frac{\alpha}{2}})$;

4) 计算 $\frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$, 若在接受域中, 则 H_0 被接受, 否则被拒绝.




(2) T — 检验 (σ^2 未知)

1) 设 $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$;

2) 选择统计量 $\frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}} \sim t(n-1)$;

3) 接受域 $(-t_{\frac{\alpha}{2}}(n-1), t_{\frac{\alpha}{2}}(n-1))$;

4) $\frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}$, 若在接受域中, 则 H_0 被接受, 否则 H_0 被拒绝.




(3) χ^2 -检验 (μ 未知)

1) $H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2;$

2) 选择统计量 $\frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$

3) 接受域 $(\chi_{1-\frac{\alpha}{2}}^2(n-1), \chi_{\frac{\alpha}{2}}^2(n-1));$

4) 计算 $\frac{(n-1)S^2}{\sigma_0^2}$, 若在接受域中, 则 H_0 被接受, 否则 H_0 被拒绝.



(4) χ^2 -检验 (μ 已知)

1) $H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2;$

2) 选择统计量 $\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma_0^2} \sim \chi^2(n)$

3) 接受域 $(\chi_{1-\frac{\alpha}{2}}^2(n), \chi_{\frac{\alpha}{2}}^2(n));$

4) 计算 $\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma_0^2}$, 若在接受域中, 则 H_0 被接受, 否则 H_0 被拒绝.

众数, 中位数