

概率论

随机现象建模，揭示其内在规律

概率公理(柯尔莫果洛夫公理)

第一公理(非负性): 任何事件的概率 $P(A) \geq 0$

第二公理(归一化): 整个样本集合发生的概率是1

第三公理(可加性): 任意两两不相交事件 $E_1, E_2, \dots$ 的可数序列满足 $P(E_1 \cup E_2 \cup \dots) = \sum P(E_i)$

随机事件和概率

排列组合

- 乘法原理和加法原理
- 排列和组合

事件

- 事件之间的关系(包含关系,事件相等,积事件,和事件,差事件,互斥,对立,独立)
- 事件的运算律(交换,结合,分配,德摩根律)
- 加法公式和减法公式

古典型概率

基本假设: 所有基本事件发生的可能性 **完全相同**, 且样本空间是 **有限的**

总结: **有限均匀离散点**

计算公式:

$$P(A) = \frac{A \text{ 中基本事件的个数}}{\Omega \text{ 中基本事件的总数}}$$

缺点: 现实中很多样本点无法做到等可能,无法处理无限样本空间

问题场景: 针对 **离散有限** 问题

前置知识: **组合数学**

几何型概率

基本假设: 将概率与 **几何度量** (长度、面积、体积) 关联, 用于 **连续型样本空间**

总结: **无限均匀连续区间**

计算公式:

$$P(A) = \frac{A \text{ 的长度 (面积或体积)}}{\Omega \text{ 的长度 (面积或体积)}}$$

缺陷

依赖几何空间的均匀性假设，实际问题中可能不符合；
高维空间计算复杂度高

问题场景：针对连续无限问题

前置知识：需要测度论

条件概率

背景：事件之间往往相互依赖,需要进行刻画

作用：突破均匀性假设,允许在非均匀或部分已知信息下灵活(动态)调整

计算公式：

$$P(B|A) = \frac{P(AB)}{P(A)}$$

常见性质

$$1) \quad 0 \leq P(B|A) \leq 1$$

$$2) \quad P(\Omega|A) = 1$$

$$3) \quad P(\bar{A}|B) = 1 - P(A|B)$$

$$4) \quad P((A_1 \cup A_2)|B) = P(A_1|B) + P(A_2|B) - P(A_1 A_2|B)$$

独立事件

条件： $P(AB) = P(A)P(B)$

等价条件： $P(B|A) = P(B|\bar{A})$ ($P(A) \neq 0$ and $P(A) \neq 1$)

意义：两个信息之间无关联,简化条件概率的计算

相互独立

$$P(AB) = P(A)P(B) \text{ and } P(AC) = P(A)P(C) \text{ and } P(BC) = P(B)P(C) \text{ and } P(ABC) = P(A)P(B)P(C)$$

全概率公式

假设：完备时间组(互斥且并集为全集)

公式：

$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i)$$

意义: 解决更复杂的概率计算问题

贝叶斯公式

思想：贝叶斯公式通过将**先验概率**（已有知识）与**似然函数**（新证据）结合，计算**后验概率**（更新后的信念）

公式：

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

$$P(\text{假设 } H | \text{数据 } D) = \frac{P(D|H) \cdot P(H)}{P(D)}$$

意义: 动态更新数据,量化不确定性,支持因果推理

效果:

- 当数据量足够大时, 后验概率逐渐收敛, 受先验的影响减弱。
- 当数据稀缺时, 先验对后验起主导作用

一维随机变量及其分布

一维随机变量概述

定义 将样本空间中的每个结果映射到实数函数 $X: \Omega \rightarrow \mathbb{R}$

随机变量的分布函数(CDF)

定义: 设 X 是一个随机变量, 对于任意实数 x , 令 $F(x) = P(X \leq x)$, 则称 $F(x)$ 为随机变量 X 的概率分布函数, 简称分布函数。

分布函数的性质

非负性: $0 \leq F(x) \leq 1$;


规范性: $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$, $F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1$;

单调不减性: 对于任意 $x_1 < x_2$, 有 $F(x_1) \leq F(x_2)$;

右连续性: $F(x) = F(x+0)$.

连续型随机变量的概率分布(PDF)

若对于随机变量 X 的分布函数 $F(x)$, 存在非负可积函数 $f(x) \geq 0 (-\infty < x < +\infty)$, 使得对于任意实数 x , 有 $F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$, 则称 X 为连续型随机变量, 函数 $f(x)$ 称为 X 的概率密度函数 (简称概率密度)。



PDF的性质

非负性: $f(x) \geq 0$.

规范性: $\int_{-\infty}^{\infty} f(x) dx = 1$.

连续型随机变量 X 的分布函数 $F(x)$ 是连续函数, 因此在任何给定值的概率都是零, 即对于任何实数 a , 有 $P(X = a) = 0$.

对于任意实数 a 和 b ($a < b$), 有 $P(a < X \leq b) = F(b) - F(a) = \int_a^b f(x) dx$.

在 $f(x)$ 的连续点处, 有 $F'(x) = f(x)$.

离散型随机变量

0-1分布

假设 随机变量 X 只有0和1两个取值

概率质量函数 $P(X = x) = p^{x_i}(1 - p)^{1-x_i}$, $x_i = 0, 1$

二项分布

记法 $X \sim B(n, p)$

假设 任意一次实验中出现的概率是 $p(0 < p < 1)$. X 表示 n 重伯努利试验中事件 A 发生的次数, 则 X 所有可能的取值为 $0, 1, 2, \dots, n$, 且相应的概率为

概率质量函数

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n.$$

几何分布

假设 在n次伯努利试验中，试验k次才得到第一次成功的机率

概率质量函数 $P(X = k) = (1 - p)^{k-1} p, (0 < p < 1), k = 1, 2, \dots$

超几何分布

记法 $X \sim H(N, M, n)$

假设 有限总体抽样不放回的成功次数 结果相互依赖

概率质量函数 $P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, \max(0, n - (N - M)) \leq k \leq \min(n, M)$

- ***N***: 总体的总数量。
- **M*M***: 总体中“成功”的数量。
- **n*n***: 抽取的样本数量。

泊松分布

记法 $X \sim P(\lambda)$

假设 不同事件段内事件的发生是相互独立的 事件在时间段内平均发生 事件在短时间内发生的概率很小

概率质量函数 $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$

连续型随机变量


均匀分布

记法 $X \sim U(a, b)$


假设 有限范围 等可能性

概率密度函数

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{if } a < x < b, \\ 0 & \text{otherwise.} \end{cases}$$



概率分布函数



$$F(x) = \begin{cases} 0 & \text{if } x < a, \\ \frac{x-a}{b-a} & \text{if } a \leq x < b, \\ 1 & \text{if } x \geq b. \end{cases}$$

指数分布

记法 $X \sim E(\lambda)$

假设 无记忆性 独立性和恒定性 适用于稀有事件

概率密度函数


$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{if } x > 0, \\ 0 & \text{if } x \leq 0. \end{cases}$$

概率分布函数

$$F(x) = \begin{cases} 1 - e^{-x} & \text{if } x > 0, \\ 0 & \text{if } x \leq 0. \end{cases}$$

性质

$$P\{X > s+t \mid X > s\} = P\{X > t\}. \text{ 无记忆性}$$



二八定律不是指数分布,是幂律分布


无记忆性: 一个过程未来发生的概率与过去已经发生的时间无关

正态分布

记法 $X \sim N(\mu, \sigma^2)$

假设

概率密度函数



$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad (-\infty < x < +\infty)$$

- μ : 均值, 表示分布的中心位置;
- σ : 标准差, 表示分布的散布程度;
- σ^2 : 方差。

标准正态分布

$$Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$$

概率分布函数

$$F(x) = P(X \leq x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

一维随机变量函数分布

概率分布: $P(X=x_k)=p_k, k=1,2,\dots$

随机变量X的函数 $Y = g(x_k)$ 的概率为 $P(Y = g(x_k)), k=1,2,3,\dots$

注意: 若出现相同的函数值, 应该算作一个取值的概率

离散型随机变量的函数分布

1. 取值求解法

连续型随机变量的函数分布

求解概率密度的方法:

1. 分布函数法

先求随机变量 Y 的分布函数 $F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx$, 然

后分布函数求导得概率密度 $f_Y(y) = F'_Y(y)$.

2. 公式法

若 $y = \varphi(x)$ 严格单调且其反函数 $x = h(y)$ 连续可导, 则 $Y = \varphi(X)$ 的密度为

$$f_Y(y) = \begin{cases} f_X[h(y)] |h'(y)|, & \alpha < y < \beta \\ 0, & \text{其他} \end{cases}, \text{ 其中 } (\alpha, \beta) \text{ 为函数 } y = \varphi(x) \text{ 的值域。}$$

二维随机变量及其分布

二维随机变量概述

分布函数

二维随机变量及其分布函数

定义: 设 $X=X(\omega), Y=Y(\omega)$ 是定义在样本空间 $\Omega=\{\omega\}$ 上的两个随机变量, 则称向量 (X, Y) 为二维随机变量 (或随机向量)。

联合分布函数

联合分布函数: 设 (X, Y) 是二维随机变量, 对于任意实数 x, y , 称二元函数 $F(x, y) = P(X \leq x, Y \leq y)$ 为二维随机变量 (X, Y) 的分布函数或随机变量 X 与 Y 的联合分布函数, 它表示随机事件 $\{X \leq x\}, \{Y \leq y\}$ **同时发生的概率**。

性质:

非负性: 对于任意实数 $x, y \in \mathbb{R}$, $0 \leq F(x, y) \leq 1$;

规范性:

$$F(-\infty, y) = \lim_{x \rightarrow -\infty} F(x, y) = 0, \quad F(x, -\infty) = \lim_{y \rightarrow -\infty} F(x, y) = 0,$$

$$F(-\infty, -\infty) = \lim_{x \rightarrow -\infty, y \rightarrow -\infty} F(x, y) = 0, \quad F(+\infty, +\infty) = \lim_{x \rightarrow +\infty, y \rightarrow +\infty} F(x, y) = 1.$$

单调性: $F(x, y)$ 分别关于 x 和 y 单调不减;

右连续性: $F(x, y)$ 分别关于 x 和 y 右连续, 即

$$F(x, y) = F(x+0, y), \quad F(x, y) = F(x, y+0), \quad x, y \in \mathbb{R}.$$

边缘分布函数

边缘分布函数: 设二维随机变量 (X, Y) 的分布函数为 $F(x, y)$, 则称

$$F_X(x) = P\{X \leq x\} = P\{X \leq x, Y < +\infty\} = F(x, +\infty) = \lim_{y \rightarrow +\infty} F(x, y)$$

是二维随机变量 (X, Y) 关于 X 的边缘分布函数。

同理, $F_Y(y) = F(+\infty, y) = \lim_{x \rightarrow +\infty} F(x, y)$ 为二维随机变量 (X, Y) 关于 Y 的边缘分布函数。

独立性

定义 设二维随机变量 (X, Y) 的分布函数为 $F(x, y)$, 关于 X 和关于 Y 的边缘分布函数分别为 $F_X(x)$ 和 $F_Y(y)$ 。如果对于任意实数 x 和 y 有 $F(x, y) = F_X(x)F_Y(y)$, 则称随机变量 X 和 Y 相互独立。

离散型: X, Y 独立 $\Leftrightarrow p_{ij} = p_i \times p_j, i = 1, 2, \dots, m, j = 1, 2, \dots, n$;

连续型: X, Y 独立 $\Leftrightarrow f(x, y) = f_X(x)f_Y(y)$ (对几乎所有的 x, y 成立即可, 不要求所有有的 x, y , 因为连续型随机变量在个别点上的概率为零, 不允许在区域上该等式不成立)。

离散型随机变量

定义 如果二维随机变量 (X, Y) 可能取值为 **有限对或无限可列多对实数**, 则称 (X, Y) 为二维离散型随机变量。

联合分布

设二维离散型随机变量 (X, Y) 所有可能取值为 $(x_i, y_j)(i, j = 1, 2, \dots)$, 且对应的概率为

$$P(X = x_i, Y = y_j) = p_{ij} \quad (i, j = 1, 2, \dots),$$

且满足: 1. $p_{ij} \geq 0, i, j = 1, 2, \dots$, 2. $\sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} p_{ij} = 1$,

则称为二维离散型随机变量 (X, Y) 的概率分布或随机变量 X 和 Y 的联合概率分布。

边缘分布

对于二维离散型随机变量 (X, Y) , 它的概率分布为

$$P(X = x_i, Y = y_j) = p_{ij}, \quad i, j = 1, 2, \dots$$

则 X 的边缘分布为 $P(X = x_i) = P(X = x_i, Y < +\infty) = \sum_{j=1}^{+\infty} P(X = x_i, Y = y_j) = \sum_{j=1}^{\infty} p_{ij} = p_i \quad (i = 1, 2, \dots)$

边缘分布函数 $F_X(x) = P(X \leq x) = \sum_{x_i \leq x} P(X = x_i) = \sum_{x_i \leq x} p_i$

条件分布

设二维离散型随机变量 (X, Y) 的概率分布为 $P(X = x_i, Y = y_j) = p_{ij}, i, j = 1, 2, \dots$

对于给定的 j , 如果 $P(Y = y_j) > 0(j = 1, 2, \dots)$, 则称

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_j}, i = 1, 2, \dots$$

为在 $Y = y_j$ 条件下随机变量 X 的条件概率分布。

对于给定的 i , 如果 $P(X = x_i) > 0(i = 1, 2, \dots)$, 则称

$$P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)} = \frac{p_{ij}}{p_i}, j = 1, 2, \dots$$

为在 $X = x_i$ 条件下随机变量 Y 的条件概率分布。

连续型随机变量

定义

设二维随机变量 (X, Y) 的分布函数为 $F(x, y)$, 如果存在非负可积的二元函数 $f(x, y)$, 使得对任意实数 x, y , 有 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$, 则称 (X, Y) 为 **二维连续型随机变量**, 称函数 $f(x, y)$ 为二维随机变量 (X, Y) 的 **概率密度函数** 或随机变量 X 和 Y 的 **联合概率密度**。

性质

$$f(x, y) \geq 0;$$

$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1;$$

若 $f(x, y)$ 在点 (x, y) 处连续, 则有 $f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$;

设 D 是 xy 平面上任一区域, 则点 (x, y) 落在 D 内的概率为: $P((X, Y) \in D) = \iint_D f(x, y) dx dy$.

边缘概率密度

定义: 设 (X, Y) 为连续型随机变量, 它的概率密度函数为 $f(x, y)$.

X 的边缘概率密度为 $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$

Y 的边缘概率密度为 $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$

通常分别称 $f_X(x)$ 和 $f_Y(y)$ 为二维随机变量 (X, Y) 关于 X 和 Y 的边缘概率密度.

条件概率密度

设二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, 则

对于给定的实数 y , 边缘概率密度 $f_Y(y) > 0$, 则称 $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$ 为在条件 $Y = y$ 下 X 的条件概率密度。

对于给定的实数 x , 边缘概率密度 $f_X(x) > 0$, 则称 $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$ 为在条件 $X = x$ 下 Y 的条件概率密度。

二维均匀分布

假设 有限区域的等可能

联合密度公式

$$f(x, y) = \begin{cases} \frac{1}{S_G} & \text{if } (x, y) \in G \\ 0 & \text{if } (x, y) \notin G \end{cases}$$

S_G 是 G 面积

性质

若在各边平行于坐标轴的矩形区域 $D = \{(x, y) \mid a \leq x \leq b, c \leq y \leq d\}$ 上服从均匀分布的随机变量 (X, Y) , 则它的两个分量 X 和 Y 是独立的, 并且分别服从区间 $[a, b]$ 和 $[c, d]$ 上的一维均匀分布。

二维正态分布

记法 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2, \rho)$

联合密度函数

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}, x, y \in \mathbb{R}$$

其中 $\mu_1, \mu_2, \sigma_1 > 0, \sigma_2 > 0, -1 < \rho < 1$ 均为常数

性质

若 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2, \rho)$

1. 边缘分布都是服从一维正态分布, 即 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$.
2. X 和 Y 任意的非零线性组合 $aX + bY$ 服从一维正态分布.
3. X 和 Y 相互独立的充要条件是相关系数 $\rho = 0$.

二维随机变量函数的分布

$P(X = x_i, Y = y_j) = p_{ij}, i, j = 1, 2, \dots$ 则 $Z = P(X, Y)$ 的概率分布求解

离散型随机变量函数的概率分布

1. 直接求解

注意 相同的值需要合并

连续型随机变量函数的概率分布

已知二维连续型随机变量 (X, Y) 的概率密度为 $f(x, y)$ ，求随机变量函数 $Z = g(X, Y)$ 的概率密度 $f_Z(Z)$ 。

采用分布函数法：先求出 Z 的分布函数 $F_Z(z)$ ，然后求导得到概率密度 $f_Z(z) = F'_Z(z)$ 。

设 $Z = g(X, Y)$ 的分布函数为 $F_Z(z)$ ，则

$$F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f(x, y) dx dy.$$

主要思路: 根据定义和概率密度函数求解

常见函数分布

$$U = \min\{X, Y\}, V = \max\{X, Y\}$$

设 X, Y 相互独立，且分布函数分别为 $F_X(x), F_Y(y)$ ，则

$$\begin{aligned} F_U(u) &= P\{U \leq u\} = P\{\min\{X, Y\} \leq u\} = 1 - P\{\min\{X, Y\} > u\} \\ &= 1 - P\{X > u, Y > u\} = 1 - P\{X > u\}P\{Y > u\} = 1 - [1 - P\{X \leq u\}] \cdot [1 - P\{Y \leq u\}] \\ &= 1 - [1 - F_X(u)] \cdot [1 - F_Y(u)]. \end{aligned}$$

$$\begin{aligned} F_V(v) &= P\{V \leq v\} = P\{\max\{X, Y\} \leq v\} = P\{X \leq v, Y \leq v\} \\ &= P\{X \leq v\}P\{Y \leq v\} = F_X(v)F_Y(v). \end{aligned}$$

注意如果此处变量是离散的，取值求解

独立和卷积公式

随机变量 $Z = X + Y$ 的概率密度函数 $f_Z(z)$ ，其中 $f_X(x)$ 是 X 的概率分布， $f_Y(y)$ 是 Y 的概率密度

$$\text{若 } X \text{ 与 } Y \text{ 独立，则 } f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx \text{ 或 } f_Z(z) = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy,$$

这个公式称为独立和卷积公式。

拓展:

其中 $f(x, y)$ 是联合概率密度函数

已经 $z = g(x, y)$, 解出 $y = h(x, z)$

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, h(x, z)) \left| \frac{\partial h}{\partial z} \right| dx$$

$Z = \frac{Y}{X}$ 的分布、 $Z = XY$ 的分布

$$f_{Y/X}(z) = \int_{-\infty}^{+\infty} |x| f(x, xz) dx,$$

$$f_{XY}(z) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f(x, \frac{z}{x}) dx.$$

性质

$$U = X + Y$$

$X \sim B(m, p), Y \sim B(n, p)$, 且 X, Y 独立, 则 $U \sim B(m+n, p)$

$X \sim P(\lambda_1), Y \sim P(\lambda_2)$, 且 X, Y 相互独立, 则 $U \sim P(\lambda_1 + \lambda_2)$

若随机变量 X, Y 相互独立, 且 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 则随机变量

$Z = aX + bY$ (其中 a, b 为常数) 仍然服从正态分布, 且 $Z \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$.

随机变量的数字特征

期望

一、随机变量的数学期望

1 离散型随机变量的数学期望

(1) 一维离散型随机变量的数学期望

设随机变量 X 的概率分布为 $P\{X = x_i\} = p_i (i = 1, 2, \dots)$, 若级数 $\sum_{i=1}^{\infty} x_i p_i$ 绝对收敛, 则称

$\sum_{i=1}^{\infty} x_i p_i$ 为随机变量 X 的数学期望, 记作 $E(X)$, 即 $E(X) = \sum_{i=1}^{\infty} x_i p_i$; 如果级数 $\sum_{i=1}^{\infty} |x_i| p_i$

发散, 则称 X 的数学期望不存在.

(2) 一维离散型随机变量函数的数学期望

若 X 是离散型随机变量, 其概率分布为 $P\{X = x_i\} = p_i (i = 1, 2, \dots)$, $g(x)$ 为连续函数,

$Y = g(X)$, 若级数 $\sum_{i=1}^{\infty} g(x_i) p_i$ 绝对收敛, 则 $E[g(X)]$ 存在, 且

$$E[g(X)] = \sum_{i=1}^{\infty} g(x_i) p_i.$$

(3) 二维离散型随机变量函数的数学期望

若 (X, Y) 是二维离散型随机变量, 其概率分布为

$P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots, g(x, y)$ 为二元连续函数, $Z = g(X, Y)$, 当

$\sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} g(x_i, y_j) p_{ij}$ 绝对收敛时 $E[g(X, Y)]$ 存在, 且

$$E(Z) = E[g(X, Y)] = \sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} g(x_i, y_j) p_{ij}.$$

2 连续型随机变量的数学期望

(1) 一维连续型随机变量的数学期望

设连续型随机变量 X 的概率密度为 $f(x)$ ，若积分 $\int_{-\infty}^{+\infty} xf(x)dx$ 绝对收敛，则称积分

$\int_{-\infty}^{+\infty} xf(x)dx$ 为 X 的数学期望，记 $E(X)$ ，即 $E(X) = \int_{-\infty}^{+\infty} xf(x)dx$ ；若积分

$\int_{-\infty}^{+\infty} |x|f(x)dx$ 发散，则称 X 的数学期望不存在。

(2) 一维连续型随机变量函数的数学期望

若 X 是连续型随机变量，其密度函数为 $f_X(x)$ ， $g(x)$ 为连续函数， $Y = g(X)$ ，若积分

$\int_{-\infty}^{+\infty} g(x)f_X(x)dx$ 绝对收敛，则 $E[g(X)]$ 存在，且

$$E(Y) = E[g(X)] = \int_{-\infty}^{+\infty} g(x)f_X(x)dx$$

(3) 二维连续型随机变量函数的数学期望

若 (X, Y) 是二维连续型随机变量，其密度函数为 $f(x, y)$ ， $Z = g(x, y)$ 则当广义积分

$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y)f(x, y)dxdy$ 绝对收敛时， $E[g(X, Y)]$ 存在，且

$$E(Z) = E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y)f(x, y)dxdy$$

3 随机变量数学期望的性质

(1) 设 c 为常数，则有 $E(c) = c$

(2) 设 X 为一随机变量，且 $E(X)$ 存在， c 为常数，则有 $E(cX) = cE(X)$ ；

(3) 设 X 与 Y 是两个随机变量，则有 $E(X+Y) = E(X) + E(Y)$

(4) 设 X 与 Y 相互独立，则有 $E(XY) = [E(X)][E(Y)]$

方差

1 随机变量方差的定义

设 X 是一个随机变量，如果 $E\{[X - E(X)]^2\}$ 存在，则称 $E\{[X - E(X)]^2\}$ 为 X 的方

差，记作 $D(X)$ ，即 $D(X) = E\{[X - E(X)]^2\}$ ，称 $\sqrt{D(X)}$ 为标准差或均方差。

2 方差的计算

(1) 定义法

离散情形：若 X 是离散型随机变量，其概率分布为 $P\{X = x_i\} = p_i, i = 1, 2, \dots$

$$D(X) = E\{[X - E(X)]^2\} = \sum_i [x_i - E(X)]^2 p_i.$$

连续情形：设连续型随机变量 X 的概率密度为 $f(x)$ ，则

$$D(X) = E[X - EX]^2 = \int_{-\infty}^{+\infty} [x - EX]^2 f(x) dx$$

(2) 公式法

$$D(X) = E(X^2) - [E(X)]^2.$$

3 方差的性质

(1) 设 c 为常数，则 $D(c) = 0$.

(2) 如果 X 为随机变量， c 为常数，则 $D(cX) = c^2 D(X)$.

(3) 如果 X 为随机变量， c 为常数，则有 $D(X + c) = D(X)$.

由性质 (2) (3) 可得 $D(aX + b) = a^2 D(X)$ (a, b 为任意常数).

(4) $D(X \pm Y) = D(X) + D(Y) \pm 2E\{[X - E(X)][Y - E(Y)]\}$

常用随机变量的数学期望和方差

分布名称	分布记号	期望	方差
0-1 分布	$X \sim B(1, p)$	p	$p(1-p)$
二项分布	$X \sim B(n, p)$	np	$np(1-p)$
泊松分布	$X \sim P(\lambda)$	λ	λ
几何分布	$X \sim G(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
均匀分布	$X \sim U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布	$X \sim E(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布	$X \sim N(\mu, \sigma^2)$	μ	σ

协方差和相关系数

1 协方差

(1) 定义: (X, Y) 是二维随机变量, 设 $E(X)$ 和 $E(Y)$ 都存在, 若

$E\{[X - E(X)][Y - E(Y)]\}$ 存在, 则称其为随机变量 X 和 Y 的协方差, 记 $Cov(X, Y)$,

即 $Cov(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$.

(2) 计算公式

对于任意两个随机变量 X 和 Y , 有: $Cov(X, Y) = E(XY) - E(X)E(Y)$

(3) 性质

1) $Cov(X, Y) = Cov(Y, X)$;

2) $Cov(aX, bY) = abCov(X, Y)$, 其中 a, b 为任意常数;

3) $Cov(c, X) = 0$ 其中 c 为任意常数;

4) $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$;

5) 如果 X 和 Y 相互独立, 则 $Cov(X, Y) = 0$.

$$cov(ax + by, ax - by) = a^2 D(x) - b^2 D(y)$$

2 相关系数

(1) 定义: (X, Y) 是二维随机变量, 设 X 和 Y 的方差均存在, 且都不为零, 则称

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}} \text{ 为 } X \text{ 和 } Y \text{ 的 (线性) 相关系数.}$$

(2) 相关系数的性质

1) $|\rho_{XY}| \leq 1$

2) $|\rho_{XY}| = 1$ 的充分必要条件是 X 和 Y 以概率 1 线性相关, 即存在常数 a 和 b , 使得

$$P\{Y = aX + b\} = 1, \text{ 当 } a > 0 \text{ 时, } \rho_{XY} = 1; a < 0 \text{ 时, } \rho_{XY} = -1.$$

相关不等于有因果, 反应线性关系

独立一定是不相关的, 但是不相关不一定是独立, 可能是非线性相关

正态分布中, 只有线性相关和不相关

概率思维不是因果思维

大数定律和中心极限定理

大数定律

设 $X_1, X_2, \dots, X_n, \dots$ 是一个随机变量序列, a 是一个常数, 如果对于任意给定的正数 ε , 有

$\lim_{n \rightarrow \infty} P\{|X_n - a| < \varepsilon\} = 1$, 则称随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 依概率收敛于 a , 记作

$$X_n \xrightarrow{P} a.$$

切比雪夫大数定律 (一般情形)

设 $X_1, X_2, \dots, X_n, \dots$ 是由两两不相关 (或两两独立) 的随机变量所构成的序列, 分别具有

数学期望 $E(X_1), E(X_2), \dots, E(X_n), \dots$ 和方差 $D(X_1), D(X_2), \dots, D(X_n), \dots$, 并且方差

有公共上界, 即存在正数 M , 使得 $D(X_n) \leq M, n = 1, 2, \dots$, 则对于任意给定的正数 ε ,

$$\text{总有 } \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n EX_k\right| < \varepsilon\right\} = 1.$$

X 的数据可能来自不同的分布, 即研究的问题不同, 但是会趋于一个均值

注意: $n \rightarrow \infty$, 可理解为拆为不同的小组, 还有很多在很远处数据来自同分布

独立同分布的切比雪夫大数定律（特殊情形）

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立，服从相同的分布，具有数学期望 $E(X_n) = \mu$ 和方差 $D(X_n) = \sigma^2$ ($n=1, 2, \dots$) 则对于任意给定的正数 ε ，总有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \varepsilon \right\} = 1$$

即随机变量序列 $\overline{X}_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$ 。

辛钦大数定律

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立，服从相同的分布，具有数学期望

$E(X_n) = \mu$ ($n=1, 2, \dots$)，则对于任意给定的正数 ε ，总有 $\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \varepsilon \right\} = 1$ 。

伯努利大数定律

设在每次实验中事件 A 发生的概率 $P(A) = p$ ，在 n 次独立重复实验中，事件 A 发生的频率为 $f_n(A)$ ，则对于任意正数 ε ，总有 $\lim_{n \rightarrow \infty} P \{ |f_n(A) - p| < \varepsilon \} = 1$ 。


大数据下，数据充分的条件下，频率将收敛于真实的概率

中心极限定理

棣莫弗—拉普拉斯中心极限定理

设随机变量 X_n 服从参数为 n 和 p 的二项分布，即 $X_n \sim B(n, p)$ ($0 < p < 1, n=1, 2, \dots$)，则对于任意实数 x ，有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{X_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \Phi(x).$$



二项分布在数量很多下，逼近正态分布

列维——林德伯格中心极限定理

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立，服从相同的分布，具有数学期望 $E(X_n) = \mu$ 和方

差 $D(X_n) = \sigma^2 (n=1, 2, \dots)$ 则对于任意实数 x ，有 $\lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n\sigma^2}} \leq x \right\} = \Phi(x)$.

独立同分布下的大量数据，得到的样本的和趋近正态分布